

Anticipar qué clientes se van

Un sistema para priorizar el esfuerzo de retención
en la cartera de tarjetas de crédito

En una línea

Sobre una cartera de prueba de 2.026 clientes, el sistema señaló a 396 para contactar. De esos, 308 efectivamente se iban. Detectó 308 de las 325 bajas reales: **95% de las bajas, llamando al 20% de la cartera.**

Pablo Santiago Martínez Soler
Septiembre de 2026

Resumen ejecutivo

El banco pierde cada año alrededor de 16 de cada 100 clientes de tarjeta. Recuperar un cliente perdido cuesta bastante más que retenerlo a tiempo, pero el equipo de retención no puede llamar a todo el mundo. La pregunta práctica no es *quién se va a ir* sino **a quién conviene llamar primero**.

Este trabajo construye un sistema que ordena la cartera de mayor a menor riesgo de baja y define un punto de corte: a partir de ahí, se llama. Lo que sigue son los resultados sobre un grupo de clientes que el sistema nunca había visto: 2.026 personas apartadas desde el principio justamente para poder medirlo con honestidad.

Qué pasó con esos clientes

	Clientes	Qué significa
Los llamamos y se estaban yendo	308	Acertamos. Son las bajas que se pueden evitar.
Los llamamos y se quedaban igual	88	Les damos una promoción que no hacía falta. Es el desperdicio.
No los llamamos y se fueron	17	Se nos escaparon. Es la pérdida que no vimos venir.
No los llamamos y se quedaron	1.613	Correcto. No gastamos nada en ellos.

Los tres números que importan

De cada 100 clientes que se estaban por ir, detectamos 95. Sólo 17 se escaparon sin que los viéramos.

De cada 100 llamados que hacemos, 78 van a alguien que se estaba yendo. Los otros 22 son promociones que regalamos a gente que se quedaba igual.

Llamamos a 20 de cada 100 clientes, no a toda la cartera.

Contra qué se compara

Un sistema de este tipo sólo tiene sentido si mejora lo que se haría sin él. Las dos alternativas obvias son no hacer nada y llamar a todos. Usando los supuestos de costo que se explican más abajo:

Qué hacemos	A cuántos llamamos	Bajas que evitamos	Promos regaladas	Costo total
No hacer nada	0	0	0	32.500
Llamar a toda la cartera	2.026	325	1.701	25.515
Usar el sistema	396	308	88	3.020

El costo baja un 91% respecto de no hacer nada. Frente a llamar a todos, se evitan 1.630 llamados y se pierden apenas 17 bajas.

Cuánta gente conviene llamar

Esta es la decisión central del sistema, y no es una decisión técnica: es de negocio. El modelo le pone a cada cliente un puntaje de riesgo entre 0 y 1. Alguien tiene que decidir a partir de qué puntaje se levanta el teléfono. Bajar ese corte significa llamar a más gente: se atrapan más bajas, pero también se reparten más promociones a clientes que se quedaban igual.

El equipo de retención dijo que puede manejar hasta el 30% de la cartera por campaña. La tentación es usar todo ese cupo. Conviene mirar qué se gana y qué se paga:

Si llamamos al...	Llamados	Bajas evitadas	Promos regaladas	De cada 100 llamados, cuántos se iban de verdad
20% de la cartera	396	308	88	78
30% de la cartera	596	324	272	54


Por qué nos quedamos en el 20%

Pasar del 20% al 30% de la cartera significa hacer **200 llamados más** para retener **16 bajas adicionales**. Los otros 184 llamados van a clientes que se quedaban igual: son 184 promociones regaladas. **Casi doce promociones desperdiciadas por cada baja extra que se retiene.**

Dicho de otro modo: en el 20%, de cada 100 personas que llamamos 78 se estaban yendo de verdad. En el 30%, sólo 54. La mitad de la campaña se gasta en gente que no la necesitaba.

La capacidad del equipo es un **techo, no una meta**. Que se pueda llamar al 30% no quiere decir que convenga.

El punto exacto de corte depende de dos números que el banco conoce mejor que este análisis: cuánto vale un cliente que se va y cuánto cuesta la promoción que se le ofrece a quien no se iba. Acá se usó una relación de aproximadamente 7 a 1 —perder un cliente duele siete veces más que regalar una promoción— porque es un orden de magnitud razonable, no porque sea la cifra del banco. Con los números reales, el sistema recalcula el corte solo. Si el cliente vale más, conviene llamar a más gente; si la promoción es cara, a menos.



Cada criterio para elegir el punto de corte da un resultado distinto. En rojo, el que se adoptó.


Cómo se usa en la práctica

El sistema no devuelve una lista de sí y no. Devuelve la cartera ordenada de mayor a menor riesgo, partida en diez grupos iguales. El grupo 1 son los 203 clientes más riesgosos, el grupo 10 los más tranquilos.

Grupo	Clientes	Cuántos se fueron	De cada 100, cuántos se fueron	Bajas acumuladas hasta acá
1	203	201	99	61,9%
2	203	109	54	95,4%
3	202	14	7	99,7%
4	203	1	0	100,0%
5	202	0	0	100,0%
6 a 10	1013	0	0	100%

El primer grupo es casi todo bajas: 201 de 203 clientes se fueron. Los dos primeros grupos juntos —el 20% de la cartera— contienen el 95% de todas las bajas. Del grupo 5 en adelante no se fue absolutamente nadie.

Esto es lo que hace operativo al sistema: no hace falta discutir a quién llamar. Se baja la lista ordenada y se trabaja de arriba hacia abajo hasta donde llegue la capacidad del mes.



Izquierda: qué proporción de cada grupo se fue. Derecha: cuántas bajas se capturan según a cuánta gente se llame. La línea gris es lo que se lograría eligiendo clientes al azar.

Qué avisa que un cliente se está yendo

El cliente que se va deja de operar antes de irse. Esa es la conclusión central, y es consistente entre todos los métodos que se probaron.

Las señales que más pesan

Señal	Qué mirar
Cantidad de operaciones en el año	Es la señal más fuerte de todas, por lejos. El cliente que opera poco se está yendo.
Monto total operado en el año	Segunda señal más fuerte, muy ligada a la anterior.
Compras grandes y espaciadas	Pocas operaciones de monto alto anticipan la baja más que muchas operaciones chicas.
Saldo financiado en cero	El cliente que canceló todo su saldo y no volvió a financiar está de salida.
Frenada entre principio y fin de año	Comparar el último trimestre contra el primero: si se desaceleró, es señal.
Meses sin actividad	Cuantos más meses inactivo, más riesgo.
Llamados del cliente al banco	Contraintuitivo: el que llama más se va más. Sugiere que llama porque tiene un problema sin resolver.


Las señales que NO sirven

Vale la pena decirlo con todas las letras porque contradice la intuición habitual: **el perfil del cliente no predice nada**. Edad, género, estado civil, nivel educativo, categoría de ingresos y tipo de tarjeta no permiten distinguir quién se va. Se probaron las 23 categorías de estas seis variables y ninguna diferencia resiste el análisis.

Un ejemplo de cómo se leen mal estos datos

En un análisis anterior se destacó que las tarjetas Platinum tienen la tasa de baja más alta de todas: 23,5%. Suena a un segmento premium en fuga y a una alerta para el área de productos.

El detalle es que hay **17 clientes Platinum en la muestra, de los cuales se fueron 4**. Con uno más o uno menos, la tasa salta del 18% al 29%. No hay señal ahí: hay ruido. Cualquier tabla de tasas por categoría necesita la columna con el tamaño del grupo al lado, o induce a error.



Tasa de baja por categoría, con la cantidad de clientes de cada grupo y su margen de error. La línea roja es el promedio de la cartera. Casi todas las barras la tocan: no se distinguen del promedio.

Dos tipos de cliente en riesgo

Saber a quién llamar no dice **qué ofrecerle**. Dentro del grupo de riesgo aparecen dos perfiles que se comportan de manera muy distinta:

	Perfil de alto consumo	Perfil de bajo consumo
Cuántos son	79 clientes (20%)	317 clientes (80%)
Operaciones al año	69	41
Monto operado al año	\$ 7.502	\$ 2.177
Monto por operación	\$ 109	\$ 53
Límite de tarjeta	\$ 14.517	\$ 6.878
Uso del límite disponible	7%	20%
Frenada de fin de año	Moderada	Fuerte
Riesgo de baja	80%	77%

Lo importante de esta tabla

Los dos grupos tienen **prácticamente el mismo riesgo de irse** (80% y 77%). No se diferencian en riesgo: se diferencian en **cuánto valen**. Uno opera tres veces y media más plata al año que el otro.

El modelo ya ordenó por riesgo. Esta segmentación agrega lo que falta para decidir **cuánto invertir** en retener a cada uno.

Qué sugiere cada perfil

Alto consumo (79 clientes). Son pocos y valen mucho: unos \$ 7.502 al año cada uno. Justifican una llamada de una persona y una oferta armada a medida. La señal temprana en este grupo es la desaceleración del último trimestre, que aparece antes de que caiga el volumen anual: conviene monitorearla de cerca.

Bajo consumo (317 clientes). Son cuatro veces más y operan un tercio. Una llamada individual no se paga; corresponden acciones automáticas. Un dato llamativo: usan el 20% de su límite contra el 7% del otro grupo, con límites que son la mitad. Son clientes apretados contra su tope. Para ellos, revisar el límite puede funcionar mejor que un descuento.

Advertencia sobre esta segmentación: los dos grupos **se superponen bastante**. No son dos tipos de cliente claramente separados, sino los dos extremos de un continuo. Sirve como orientación para diseñar la oferta, no como una clasificación estricta cliente por cliente.

Qué este sistema no puede hacer

Esta sección importa tanto como la de resultados. Un modelo presentado sin sus límites se termina usando para cosas que no puede sostener.

1. No dice por qué se va cada cliente

El sistema detecta que alguien dejó de operar, no la razón. Puede haber cambiado de banco, mudado, perdido el trabajo o simplemente dejado de usar esa tarjeta. La causa hay que averiguarla en la llamada.

2. No dice si la campaña va a funcionar

Que se detecte a un cliente en riesgo no significa que sea recuperable. Es posible que quienes más fácil se detectan sean justamente los que ya decidieron irse y no hay oferta que los frene. **Medir esto requiere un experimento:** llamar a un grupo y dejar sin llamar a otro comparable, y comparar. Sin eso, no se puede afirmar que el sistema ahorre plata; sólo que identifica bien a quién se va.

3. Los números de costo son supuestos, no datos del banco

No se dispuso del costo de captación, el margen por cliente ni el valor de vida. Los valores usados para fijar el corte se eligieron por su relación entre sí. Reemplazarlos por las cifras reales del banco es el primer paso antes de convertir esto en presupuesto.

4. Los resultados son demasiado buenos para un banco real

El sistema acierta mucho más de lo que sería esperable con datos bancarios reales. Se revisó que no hubiera errores de método —y no los hay, el detalle está en el anexo— pero la explicación más probable es que **la base usada, que es pública y de uso educativo, está más limpia y es más ordenada que la realidad**. En producción, con datos propios, hay que esperar un desempeño menor. Cuánto menor, sólo se sabe probándolo.

5. Los datos no tienen fechas

La base trae totales del año, no el historial mes a mes. Eso impide medir hace cuánto que un cliente no opera, que la literatura del sector señala como la señal más potente. Con datos transaccionales

fechados, el sistema mejoraría y —más importante— podría avisar con más anticipación.

Qué haría falta para ponerlo a producir

Paso	Qué implica
1. Reemplazar los supuestos de costo	Cargar el valor real del cliente y el costo de la promoción. El corte se recalcula solo.
2. Reentrenar con datos propios	Con la base real del banco, incluyendo historial con fechas si está disponible.
3. Hacer una prueba controlada	Llamar a un grupo, dejar otro sin llamar, comparar. Es la única forma de saber si la campaña sirve.
4. Definir cada cuánto se recalcula	Los hábitos de consumo cambian. Un modelo entrenado hace dos años se desactualiza sin avisar.
5. Monitorear el desempeño	Comparar cada mes lo que el modelo predijo contra lo que pasó.

Anexo metodológico

Esta sección documenta las decisiones técnicas para quien quiera auditarlas o reproducirlas. Todo el código está disponible y el pipeline es reproducible bit a bit con semilla fija.

A.1 Datos y particiones

Partición	Filas	Tasa de baja	Bajas	Nulos
train	8.101	0,1607	1.302	0
holdout	2.026	0,1604	325	0

Fuente: *Credit Card Customers* (Kaggle), 10.127 registros, 20 variables. Sin valores faltantes ni filas duplicadas. Se verificó ausencia de solapamiento entre particiones.

Columnas eliminadas. Avg_Open_To_Buy es una identidad exacta: Credit_Limit - Total_Revolving_Bal, con error absoluto máximo de $5,7 \times 10^{-14}$. Ser combinación lineal de otras columnas infla la varianza de los coeficientes en modelos lineales y reparte la importancia entre columnas redundantes en modelos de árboles. También se elimina Unnamed: 0, que es el índice de fila del archivo y no una variable.

A.2 Protocolo experimental

El orden de los pasos es lo que separa una estimación honesta de una optimista:

- **Desarrollo.** Todo el trabajo se hace sobre churn_train.csv (8.101 filas).
- **Selección de modelo.** Nueve candidatos con validación cruzada estratificada de 5 particiones, optimizando PR-AUC.
- **Calibración del umbral.** Con predicciones fuera de muestra (cross_val_predict) sobre desarrollo, nunca sobre el holdout.
- **Evaluación final.** churn_test.csv (2.026 filas) se evalúa una sola vez, con modelo y umbral ya congelados.

El tercer paso es el que corrige el error metodológico más común en este tipo de trabajos: un umbral optimizado sobre el mismo conjunto donde después se reporta desempeño es un hiperparámetro ajustado al test, y las métricas resultantes están infladas.

Preprocesamiento dentro del pipeline. El escalado y la codificación one-hot se reajustan en cada partición de la validación cruzada. Si se ajustaran una sola vez sobre todos los datos, cada partición de validación habría contribuido a la media y el desvío del escalado. El sesgo es pequeño pero sistemático, y se elimina sin costo.

A.3 Elección de la métrica

Con 16,07% de positivos, un clasificador que prediga la clase mayoritaria para todos alcanza 83,93% de exactitud y 0% de sensibilidad. La exactitud queda descartada como criterio de selección.

Se optimiza **PR-AUC** (área bajo la curva de precisión-sensibilidad), cuya línea base es la prevalencia. ROC-AUC tiene línea base 0,5 independientemente del desbalance, lo que la hace parecer más favorable de lo que es. Se reporta además el **Brier score** como medida de calibración:

un modelo puede ordenar bien y estar mal calibrado, en cuyo caso la probabilidad no se puede leer como riesgo en términos absolutos.

A.4 Tratamiento del desbalance

Se usa `class_weight='balanced'` —reponderación de la clase minoritaria en la función de pérdida— en lugar de remuestreo sintético (SMOTE, ADASYN, SMOTEENN). Con 16% de positivos y 8.101 observaciones, la clase rara no es lo bastante rara como para requerir ejemplos artificiales, y reponderar no distorsiona la distribución conjunta de las variables. El desbalance se maneja en el umbral de decisión, no alterando los datos.

A.5 Modelos evaluados


Modelo	PR-AUC	Desvío	Hiperparámetros elegidos
Hist Gradient Boosting	0,9673	0,0050	<code>l2_regularization=0.0</code> , <code>learning_rate=0.1</code> , <code>max_leaf_nodes=15</code>
Random Forest (profundidad)	0,9430	0,0148	<code>max_depth=None</code> , <code>min_samples_leaf=1</code>
Random Forest (poda ccp)	0,9430	0,0156	<code>ccp_alpha=0.0001</code>
Extra Trees	0,9232	0,0163	<code>max_depth=None</code> , <code>min_samples_leaf=1</code>
Árbol con poda ccp	0,8541	0,0299	<code>ccp_alpha=0.0</code> , <code>max_depth=None</code> , <code>min_samples_leaf=30</code>
K vecinos más cercanos	0,8325	0,0240	<code>n_neighbors=21</code> , <code>weights=distance</code>
Logística elastic net	0,7950	0,0075	<code>C=0.5</code> , <code>l1_ratio=0.2</code>
Logística L1 (lasso)	0,7949	0,0076	<code>C=0.5</code>
Logística L2 (ridge)	0,7948	0,0076	<code>C=1.0</code>

Cuatro familias con supuestos distintos: lineales regularizados (L1, L2, elastic net), no paramétricos por distancia (KNN), árbol individual con poda de coste-complejidad, y ensambles por bagging (Random Forest, Extra Trees) y por boosting (Hist Gradient Boosting).

La brecha de 17 puntos entre boosting y logística indica que el poder predictivo está en las interacciones. Ninguna correlación bivariada con la variable objetivo supera 0,4 en valor absoluto, y sin embargo el ordenamiento es casi perfecto. Los modelos lineales no pueden representar eso.

Las tres logísticas empatan hasta la tercera cifra decimal (0,7948 – 0,7950), lo que significa que la regularización no está haciendo trabajo: con 24 predictores y 8.101 observaciones no hay sobreajuste que corregir. El lasso no descarta variables porque no le sobran.

Sobre poda. Se incluyeron dos variantes de Random Forest con mecanismos distintos de control de complejidad: profundidad máxima y tamaño mínimo de hoja (prepoda) frente a poda de coste-complejidad (pospoda, `ccp_alpha`). Ambas convergen a PR-AUC 0,9430, y la pospoda selecciona `ccp_alpha=0,0001`, prácticamente sin poda. Con este tamaño de muestra el bagging ya controla la varianza por sí solo y la poda adicional no aporta.



PR-AUC por validación cruzada de 5 particiones. Las barras de error son el desvío entre particiones.

A.6 Ablación del feature engineering

Se construyeron seis variables derivadas siguiendo la lógica RFM de la literatura de churn bancario: ticket promedio, transacciones por mes, contactos por producto, ratio de inactividad, caída de actividad e indicador de saldo rotativo en cero. La base no tiene fechas, así que no se pudo construir recencia, que es el componente más predictivo según esa literatura.

Configuración	PR-AUC	Desvío
Sin variables derivadas	0,9679	0,0067
Con variables derivadas	0,9678	0,0065

Resultado negativo, reportado

Las variables derivadas no aportan nada. La diferencia está en la cuarta cifra decimal y en el sentido contrario al esperado.

Es coherente: el boosting parte recursivamente el espacio de predictores, y un cociente como monto/cantidad es reconstruible mediante cortes sucesivos en sus componentes. El feature engineering ayuda cuando el modelo no puede expresar la transformación por sí mismo —el caso de los lineales— no cuando sí puede.

Se conservan en el repositorio porque mejoran la interpretabilidad de la logística y porque un resultado negativo verificado es información.

A.7 Política de decisión

Criterio	Umbral	Precisión	Sensib.	F1	Cartera	Costo
F1 máximo	0,3301	0,900	0,919	0,909	16,4%	12.595

Criterio	Umbral	Precisión	Sensib.	F1	Cartera	Costo
Capacidad (top 30%)	0,0144	0,533	0,995	0,694	30,0%	17.740
Costo mínimo	0,1036	0,782	0,972	0,867	20,0%	8.880
Convención 0.5	0,5000	0,929	0,874	0,901	15,1%	17.705

Calculado sobre predicciones fuera de muestra del conjunto de desarrollo. Función de costo: 100 por falso negativo, 15 por falso positivo. Con costos lineales y un modelo perfectamente calibrado, el umbral óptimo teórico sería $c_{FP} / (c_{FP} + c_{FN}) = 0,130$; la grilla selecciona 0,1036, diferencia atribuible a calibración imperfecta.

El criterio adoptado es costo mínimo, configurable en `src/config.py:THRESHOLD_POLICY`. El criterio de capacidad se descarta porque el techo operativo del 30% no resulta una restricción activa: el óptimo de costo cae en 20%, holgadamente por debajo.

A.8 Interpretabilidad

Dos preguntas distintas requieren dos herramientas distintas. **Cuánto aporta cada variable:** importancia por permutación, calculada fuera de muestra. Se prefiere a `feature_importances_` de los árboles, que se computa en entrenamiento y sobrevalora variables de alta cardinalidad. **En qué dirección empuja:** odds ratios de la logística L1.

Corrección respecto de la versión original


La entrega original ajustaba LassoCV —que es **regresión lineal** con penalización L1— sobre una variable objetivo binaria, y exponenciaba los coeficientes para presentarlos como odds ratios.

Eso no es válido. Exponenciar un coeficiente de mínimos cuadrados no produce un odds ratio: produce un número sin interpretación. Los odds ratios requieren un modelo logístico, donde el coeficiente es un log-odds por construcción. En esta versión se usa `LogisticRegression(penalty='l1')`, y `src/interpret.py` levanta un `TypeError` si se le pasa un estimador sin coeficientes logísticos.

Importancia por permutación	Caída PR-AUC	Efecto direccional (logística)	Odds ratio
Cantidad de transacciones (12m)	0,2787	Ticket promedio	10,367
Monto transaccionado (12m)	0,1122	Cantidad de transacciones (12m)	0,158
Ticket promedio	0,0593	Monto transaccionado (12m)	0,166
Saldo rotativo	0,0287	Meses inactivo (12m)	3,993
Δ Monto Q4/Q1	0,0195	Meses inactivo / antigüedad	0,365
Meses inactivo / antigüedad	0,0097	Género: masculino	0,443
Edad	0,0062	Saldo rotativo en cero	2,144
Contactos por producto	0,0056	Antigüedad (meses)	0,598

Las listas coinciden en lo esencial pero difieren en el orden, porque miden cosas distintas. La logística asigna un odds ratio de 10,4 al ticket promedio; el boosting le da un tercio de la importancia que le da a la cantidad de transacciones. La diferencia surge de que la logística no puede representar la interacción entre monto y cantidad y la comprime en el cociente.

Un caso de lectura equivocada. El género masculino aparece con odds ratio 0,44, lo que sugeriría un efecto protector fuerte. Pero en la importancia por permutación el género no entra entre las diez primeras variables. Un coeficiente ajustado puede ser estadísticamente distinguible de cero y aun así no aportar capacidad predictiva. Los coeficientes de un modelo lineal mal especificado —y acá la logística lo está, dado que pierde 17 puntos contra el boosting— absorben estructura que no les corresponde.



A.9 Auditoría del desempeño anómalo

ROC-AUC de 0,9918 no es un resultado normal y no debe presentarse como mérito del modelo. Se auditó antes de reportarlo:

- Cero filas duplicadas dentro de cada partición.
- Cero solapamiento entre desarrollo y holdout (comparación sobre el vector completo de predictores).
- Ninguna variable separa por sí sola: el mejor AUC univariado es 0,796 (cantidad de transacciones).
- El preprocesamiento va dentro del pipeline, descartando fuga por escalado.
- El umbral se calibró fuera de muestra, descartando ajuste al test.
- Las métricas de validación cruzada (PR-AUC 0,9673) y de holdout (0,9655) coinciden, lo que descarta sobreajuste en la selección.

No hay fuga de información. La explicación es la naturaleza de la base: el dataset es sintético o fuertemente depurado, y resulta casi separable para ensambles de árboles. Sobre datos bancarios reales, con clases del orden del 2% y ruido de medición, un resultado de esta magnitud sería motivo para buscar el error antes que para celebrar. Se reporta con esa advertencia explícita.

A.10 Segmentación

K-medias aplicado exclusivamente dentro de la cohorte priorizada, con reducción previa por componentes principales al 90% de varianza explicada (17 componentes). La reducción es necesaria porque k-medias usa distancia euclídea, que se concentra en alta dimensión, y las

variables indicadoras del one-hot inflan la dimensión aportando poca varianza.

Segmentar toda la cartera produciría sobre todo la separación entre activos e inactivos, que el modelo predictivo ya captura y que no agrega nada accionable.

K	Silhouette	Calinski-Harabasz	Inercia
2	0,1854	53,78	9.819
3	0,0985	45,59	9.058
4	0,0911	38,85	8.602
5	0,0975	33,97	8.282
6	0,0970	30,51	8.022
7	0,0987	28,34	7.765
8	0,0802	25,90	7.605

El máximo de silhouette está en K=2 (0,1854) y cae a 0,0985 en K=3. Calinski-Harabasz apunta en la misma dirección. La inercia decrece monótonamente, como siempre, de modo que por sí sola no decide nada.

Sobre la magnitud: 0,1854 es un silhouette bajo. Indica solapamiento considerable entre grupos. Con datos de comportamiento de clientes esto es esperable —no hay tipos discretos, hay un continuo— pero significa que la segmentación describe una tendencia, no una partición nítida. Presentarla como dos perfiles claramente diferenciados excedería lo que los datos sostienen. Un modelo de mezclas gaussianas sobre los mismos datos coincide con k-medias en el 83,6% de las asignaciones.

A.11 Reproducibilidad

Semilla fija (42) en particiones, validación cruzada, modelos y clustering. El pipeline se verificó corriéndolo desde cero en un directorio limpio: los resultados de holdout, comparación de modelos y perfil de segmentos salieron idénticos bit a bit. Python 3.11, scikit-learn 1.8. Sin dependencias fuera del ecosistema estándar.

A.12 Glosario

Término técnico	Qué significa acá
Falso positivo	Cliente al que llamamos y se quedaba igual. Es una promoción regalada.
Falso negativo	Cliente que se fue sin que lo detectáramos.
Precisión	De cada 100 llamados, cuántos iban a un cliente que efectivamente se estaba yendo.
Sensibilidad (recall)	De cada 100 clientes que se iban, cuántos detectamos.
Umbral	El puntaje de riesgo a partir del cual se decide llamar.
Lift	Cuántas veces mejor que elegir al azar. Lift 6 significa seis veces más bajas por llamado.

Término técnico	Qué significa acá
Validación cruzada	Partir los datos en cinco, entrenar con cuatro y probar con la restante, cinco veces. Evita conclusiones basadas en una partición afortunada.
Holdout	Grupo de clientes apartado desde el principio y usado una sola vez, al final, para medir sin autoengaño.
PR-AUC	Métrica de calidad del ordenamiento, apropiada cuando una clase es mucho menos frecuente que la otra.
Calibración	Que una probabilidad de 0,30 corresponda a que efectivamente se vayan 30 de cada 100 clientes con ese puntaje.

Código, datos y resultados completos en el repositorio del proyecto. Este informe se genera automáticamente desde los resultados del pipeline (`scripts/build_report.py`): ninguna cifra está escrita a mano.